

KBS Ibrido per il Supporto alle Decisioni nel Catalogo Software

Integrazione di Ragionamento Deduttivo, Modelli Grafici Probabilistici e Apprendimento Supervisionato

Gruppo di lavoro

- **Domenico Tinelli**, matricola 777022, d.tinelli12@studenti.uniba.it

URL Repository: <https://github.com/dtinelli12/GameRecommendation>

Anno Accademico: 2025-2026

Indice dei Contenuti

1. [Introduzione](#)[cite: 3]
 2. [Sommario e Architettura di Sistema](#)[cite: 3]
 3. [Elenco degli Argomenti di Interesse](#)[cite: 3]
 4. [Sezione Argomento 1: Rappresentazione della Conoscenza e Ragionamento Deduttivo](#)[cite: 3]
 - [Sommario](#)[cite: 3]
 - [Strumenti utilizzati](#)[cite: 3]
 - [Decisioni di Progetto](#)[cite: 3]
 - [Valutazione](#)[cite: 3]
 5. [Sezione Argomento 2: Ragionamento in Condizioni di Incertezza \(Rete Bayesiana\)](#)[cite: 3]
 - [Sommario](#)[cite: 3]
 - [Strumenti utilizzati](#)[cite: 3]
 - [Decisioni di Progetto](#)[cite: 3]
 - [Valutazione](#)[cite: 3]
 6. [Sezione Argomento 3: Apprendimento Supervisionato e Modelli Predittivi](#)[cite: 3]
 - [Sommario](#)[cite: 3]
 - [Strumenti utilizzati](#)[cite: 3]
 - [Decisioni di Progetto](#)[cite: 3]
 - [Valutazione e Risultati Sperimentali](#)[cite: 3]
 7. [Integrazione Globale: Scoring e Formula di Rango](#)
 8. [Conclusioni e Sviluppi Futuri](#)[cite: 3]
 9. [Riferimenti Bibliografici](#)[cite: 3]
-

Introduzione


Il dominio applicativo riguarda la selezione e l'analisi decisionale all'interno del catalogo di videogiochi distribuito sulla piattaforma Steam. Tale contesto è caratterizzato da elevata eterogeneità dei dati, vincoli tassonomici rigidi, dipendenze narrative sequenziali (saghe e prequel), incertezza legata alla reputazione della community e una marcata dimensionalità delle feature descrittive (generi, fasce di prezzo, tempi medi di fruizione). Invece di ricorrere a tradizionali euristiche di filtraggio collaborativo, il problema viene affrontato formalizzando il dominio mediante un sistema a base di conoscenza capace di gestire congiuntamente vincoli logici stringenti, stime probabilistiche e predizioni statistiche.

Sommario e Architettura di Sistema

Il progetto implementa un **Knowledge-Based System (KBS) ibrido** a tre livelli, progettato per dimostrare la cooperazione sistematica tra paradigmi computazionali eterogenei:

- **Filtro Logico-Deduttivo:** Riduce lo spazio di ricerca escludendo a priori le entità non conformi ai vincoli deterministici dell'utente e alle dipendenze narrative del catalogo.
- **Inferenza Probabilistica Causal-Bayesiana:** Pesa l'ammissibilità dei candidati sotto condizioni di incertezza e informazione parziale.

- **Apprendimento Induttivo Supervisionato:** Estrae regolarità statistiche per stimare la propensione al gradimento globale, integrando il Bayesian Rating della community.



Elenco degli Argomenti di Interesse

Argomento	Sezione Programma	Tecniche e Modelli Adottati	Ruolo Operativo nel KBS
1. Rappresentazione e Deduzione	Parte II (Logica)	Clausole di Horn, Chiusura transitiva, NAF (CWA), Risoluzione SLD	Filtro vincolare deterministico e validazione saghe
2. Incertezza e Probabilità	Parte III (Reti Bayesiane)	Modelli Grafici (DAG), Stima CPT con prior BDeu, Variable Elimination	Punteggio causale sotto informazione incompleta
3. Apprendimento Supervisionato	Parte IV (Machine Learning)	Decision Tree vs Random Forest, Stratified 10-Fold CV ($\mu \pm \sigma$)	Predizione non lineare del gradimento globale

Dettaglio degli Argomenti Trattati

- **Argomento 1: Rappresentazione della Conoscenza e Ragionamento Simbolico** (*Parte II del Programma*)
 - **Formalizzazione:** Clausole di Horn definite suddivise tra fatti ground estesi (`conoscenzagiochi.pl`), fatti dinamici di profilo (`profilo_utente.pl`) e regole deduttive (`regole.pl`).
 - **Meccanismo Inferenziale:** Risoluzione SLD (Selective Linear Definite clause resolution) con strategia depth-first e backtracking automatico.
 - **Complessità Assiomatizzata:** Modellazione della continuità narrativa su grafo aciclico orientato (DAG) tramite **chiusura transitiva ricorsiva** (`da_giocare_prima/2`) e **Negation as Failure (NAF)** sotto Closed-World Assumption (`saga_rispettata/1`), superando la natura di semplice pattern-matching tabellare.
- **Argomento 2: Ragionamento in Condizioni di Incertezza** (*Parte III del Programma*)
 - **Formalizzazione:** Modello Grafico Probabilistico (Rete Bayesiana a nodi discreti) con assunzioni esplicite di indipendenza condizionata tra feature strutturali (prezzo, durata, piattaforma) e target.
 - **Apprendimento Parametri:** Stima bayesiana delle CPT con prior uniforme equivalente di Dirichlet (**BDeu**, $s = 10$) per prevenire lo *zero-frequency problem* derivante da combinazioni di feature non campionate.
 - **Inferenza Esatta:** Algoritmo di **Variable Elimination (VE)** per calcolare la distribuzione a posteriori $P(\text{Recommended} = \text{yes} \mid \mathbf{e})$ marginalizzando le variabili latenti.
- **Argomento 3: Apprendimento Automatico Supervisionato** (*Parte IV del Programma*)
 - **Modelli a Confronto:** Classificatore singolo interpretativo (**Decision Tree**, indice di impurità di Gini) contro architettura ensemble (**Random Forest**, 150 alberi con bootstrap aggregating).
 - **Scelta degli Iperparametri:** Ottimizzazione preliminare via `GridSearchCV` su 5 fold (`max_depth = 8`, `min_samples_leaf = 10`) mirata a regolarizzare l'albero e tagliare i rami dominati da generi rari per prevenire l'overfitting.
 - **Protocollo di Valutazione:** **Stratified 10-Fold Cross-Validation** con preservazione del bilanciamento delle classi e aggregazione rigorosa di media empirica e deviazione standard ($\mu \pm \sigma$) su tutte le metriche.

Sezione Argomento 1: Rappresentazione della Conoscenza e Ragionamento Deduttivo

Sommario

Il modulo implementa un motore logico-deduttivo fondato sul formalismo delle **Clausole di Horn definite** per modellare la conoscenza del dominio ed eseguire il filtraggio deterministico dei candidati. L'architettura della Base di Conoscenza (KB) è strutturata in tre componenti modulari:

- **Base di Conoscenza Estensionale** (`conoscenzagiochi.pl`): Generata programmaticamente a partire dal catalogo pre-processato, modella le istanze del dominio mediante fatti ottuari:

```
gioco(Id, Sviluppatore, Genere1, Genere2, FasciaPrezzo, CategoriaPlaytime, Piattaforma, RecCommunity).
```

- **Base di Fatti Dinamica** (`profilo_utente.pl`): Codifica le preferenze e lo storico di gioco dell'utente (interrogabili anche via Steam Web API):
 - `gia_giocato/1`: titoli già posseduti o completati.
 - `genere_gradito/1`: categorie tassonomiche di interesse.
 - `fascia_prezzo_accettabile/1`: vincoli di spesa ammissibili (`free`, `budget`, `mid_price`, `premium`).
- **Base di Conoscenza Intensionale** (`regole.pl`): Definisce gli assiomi relazionali, le regole di compatibilità e i vincoli sequenziali di fruizione.

Strumenti utilizzati

- **SWI-Prolog (v9.x)**: Interprete logico basato sul principio di Risoluzione SLD (*Selective Linear Definite clause resolution*) con strategia Depth-First e meccanismo di backtracking cronologico [1].

- **PySwip**: Libreria Foreign Function Interface (FFI) basata su CFFI/ctypes per l'orchestrazione bidirezionale tra il runtime Python e il motore Prolog [1].

Decisioni di Progetto

In accordo con i vincoli didattici (che vietano ontologie ridotte a semplici tabelle di fatti interrogate con predicati di pattern matching banali), la KB implementa una logica relazionale complessa per la gestione della **continuità narrativa delle saghe videoludiche**.

1. Modellazione del Grafo delle Saghe

Le dipendenze narrative dirette tra capitoli sono formalizzate come un grafo aciclico orientato (DAG) $\mathcal{G} = (\mathcal{V}, \mathcal{E})$, dove ogni arco $(x, y) \in \mathcal{E}$ rappresenta la relazione ground `prequel_diretto(x, y)`:

```
prequel_diretto('the_witcher_enhanced_edition', 'the_witcher_2_assassins_of_kings_enhanced_edition').
prequel_diretto('the_witcher_2_assassins_of_kings_enhanced_edition', 'the_witcher_3_wild_hunt').
```

2. Chiusura Transitiva Ricorsiva

Per verificare le dipendenze narrative a profondità arbitraria, è stata definita la chiusura transitiva $\mathcal{E}^+$ mediante induzione strutturale:

```
% Caso base: precedenza diretta
da_giocare_prima(X, Y) :-
    prequel_diretto(X, Y).

% Passo induttivo: precedenza transitiva
da_giocare_prima(X, Y) :-
    prequel_diretto(X, Z),
    da_giocare_prima(Z, Y).
```

3. Quantificazione Universale tramite Negation as Failure (NAF)

Un titolo T appartenente a una saga non può essere raccomandato se l'utente non ha completato tutti i capitoli precedenti. Formalmente:

$$\forall P (\text{da_giocare_prima}(P, T) \implies \text{gia_giocato}(P))$$

Sotto la **Closed-World Assumption (CWA)**, tale formula è convertita nella forma equivalente a quantificatore esistenziale negato:

$$\neg \exists P (\text{da_giocare_prima}(P, T) \wedge \neg \text{gia_giocato}(P))$$

In Prolog, la regola è implementata sfruttando l'operatore NAF (`\+`):

```
saga_rispettata(Titolo) :-
    \+ (da_giocare_prima(Prequel, Titolo), \+ gia_giocato(Prequel)).
```

4. Regola Conclusiva di Ammissibilità Logica

L'obiettivo decisionale `consigliato(Titolo)` unifica e seleziona i titoli ammissibili imponendo congiuntamente tutti i filtri tassonomici e relazionali:

```
consigliato(Titolo) :-
    gioco(Titolo, _Dev, G1, G2, Prezzo, _Playtime, _Platform, 'yes'),
    genere_compatibile(G1, G2),
    fascia_prezzo_accettabile(Prezzo),
```

```
\+ gia_giocato(Titolo),
saga_rispettata(Titolo).
```

Valutazione

Complessità Computazionale

Dato che il grafo delle saghe narrative $\mathcal{G} = (\mathcal{V}, \mathcal{E})$ è rigorosamente privo di cicli (DAG), la risoluzione SLD per la chiusura transitiva ha una complessità temporale nel caso peggiore limitata superiormente da $O(|\mathcal{V}| + |\mathcal{E}|)$. Ciò assicura la terminazione finita dell'albero di derivazione senza rischio di ricorsione infinita.

Riduzione dello Spazio degli Stati

Il modulo Prolog opera come filtro vincolare deterministico (hard constraint). La sua efficacia nella riduzione dello spazio di ricerca per i modelli successivi (Rete Bayesiana e Machine Learning) è sintetizzata nella seguente tabella:

Fase della Pipeline	Cardinalità Istanze	Descrizione Operativa
Spazio Totale Catalogo	1.200	Catalogo software completo estratto e discretizzato da Steam
Filtro Titoli Posseduti	1.154	Rimozione delle istanze già presenti nel profilo utente
Filtro Tassonomico & Budget	312	Selezione su genere gradito (G1 o G2) e fascia di prezzo compatibile
Filtro Chiusura Saghe (NAF)	148	Spazio finale candidati ammissibili passati al modulo probabilistico

L'applicazione congiunta della risoluzione SLD e delle regole assiomatiche produce una **riduzione dell'87.6% dello spazio di ricerca iniziale**, permettendo ai successivi moduli probabilistici e predittivi di elaborare esclusivamente un insieme ristretto di alternative ammissibili.

Sezione Argomento 2: Ragionamento in Condizioni di Incertezza (Rete Bayesiana)

Sommario

L'ammissibilità dedotta dal modulo logico costituisce una condizione necessaria ma non sufficiente per una decisione ottimale: essa opera su logica binaria e non quantifica il grado di incertezza intrinseco alla qualità del software e alla variabilità delle preferenze.

Il secondo livello del KBS modella l'incertezza attraverso un **Modello Grafico Probabilistico (Directed Acyclic Graph)**. La rete bayesiana quantifica la probabilità di gradimento di ciascun titolo ammissibile condizionata alle sue caratteristiche oggettive, gestendo correlazioni condizionali ed evidenze parziali.

Strumenti utilizzati

- pgmpy (v0.1.25)**: Libreria Python per la strutturazione formale del DAG, la stima bayesiana delle CPT e l'inferenza probabilistica esatta [1, 3].
- NetworkX**: Supporto alla validazione topologica dell'aciclicità del grafo e all'ordinamento topologico delle variabili condizionate.

Decisioni di Progetto

1. Topologia della Rete e Assunzioni di Indipendenza Condizionata

Lo spazio degli stati del modello è definito dall'insieme di variabili discrete:

$$\mathcal{V}_{BN} = \{\text{Genre, PriceCategory, PlaytimeCategory, PlatformSupport, Recommended}\}$$

La struttura delle dipendenze orientate (DAG) è stata definita imponendo assunzioni di indipendenza condizionata (*I-map*) motivate dalla fenomenologia del dominio:

- **Genre** agisce come nodo radice e genitore di **PlatformSupport**: generi altamente simulativi o gestionali complessi presentano dipendenza di distribuzione verso piattaforme singole (PC/Linux), a differenza di generi d'azione ad ampia compatibilità.
- **Recommended** (nodo foglia target, binario **yes/no**) è condizionato congiuntamente da genere, fascia di prezzo, impegno temporale richiesto e compatibilità di piattaforma.



In base alla topologia adottata, la fattorizzazione della probabilità congiunta globale risulta:

$$P(G, Pr, Pl, Pt, R) = P(G) \cdot P(Pr) \cdot P(Pt) \cdot P(Pl | G) \cdot P(R | G, Pr, Pl, Pt)$$

2. Giustificazione Ingegneristica della Discretizzazione

L'inclusione di variabili continue non discretizzate (es. prezzo in dollari float, monte ore medio esatto in minuti) genera due colli di bottiglia critici:

1. **Esplosione della dimensionalità delle CPT**: Con feature continue e campionamenti continui, la rappresentazione esatta delle distribuzioni congiunte richiede stime parametriche miste (Gaussian CPT) o partizioni a cardinalità infinita, saturando rapidamente la memoria di sistema durante l'inferenza congiunta.
2. **Fragilità dell'evidenza (OutOfDistribution / KeyError)**: In fase di query, l'osservazione di un valore continuo non campionato nel training set produce il fallimento della marginalizzazione per mancanza di densità locale.

Tutte le feature sono state discretizzate a monte in `scripts/preprocess.py` in bin finiti e mutuamente esclusivi:

- **Fasce di Prezzo**: **free** (\$0.00\$), **budget** (\$0.01\$-14.99\$), **mid_price** (15.00\$ – 29.99\$), **premium** (> 30.00\$).
- **Impegno Temporale (Playtime)**: **short** (< 5 h), **medium** (5 – 25 h), **long** (> 25 h).
- **Piattaforme**: **single_platform** (solo Windows), **multiplatform** (supporto esteso Linux/macOS).

3. Parameter Learning: Bayesian Estimator con Prior BDeu

La stima delle Tabelle di Probabilità Condizionata (CPT) tramite il classico stimatore di Massima Verosimiglianza (*Maximum Likelihood Estimator - MLE*) è inadeguata: per configurazioni di feature rare o non osservate nel dataset, MLE assegna probabilità nulla ($P = 0$), azzerando l'intero prodotto di probabilità congiunta durante l'inferenza (*zero-frequency problem*).

Si è adottato il **Bayesian Estimator con prior BDeu (Bayesian Dirichlet equivalent uniform)**:

$$P(X_i = k | \text{Pa}(X_i) = j) = \frac{N_{ijk} + \frac{s}{r_i \cdot q_i}}{N_{ij} + \frac{s}{q_i}}$$

dove r_i è il numero di stati della variabile X_i , q_i è il numero di configurazioni dei suoi nodi genitori $\text{Pa}(X_i)$, N_{ijk} è il conteggio empirico osservato, e s è la dimensione campionaria equivalente (*equivalent sample size*).

Il parametro di regolarizzazione è stato fissato a **equivalent_sample_size = 10**. Tale scelta assegna un pseudo-conteggio sufficiente a distribuire massa di probabilità sulle celle CPT prive di osservazioni, senza appiattire la varianza empirica del catalogo (come avverrebbe con valori di prior eccessivamente alti, es. $s \geq 50$).

Valutazione

Inferenza Esatta tramite Variable Elimination

Il punteggio probabilistico non richiede approssimazioni stocastiche (es. Gibbs Sampling) data la compattezza del grafo. L'inferenza è calcolata esattamente con l'algoritmo di **Variable Elimination (VE)**, marginalizzando per somme sui fattori intermedi relativi alle variabili non osservate [1, 3].

Dato un titolo ammesso dal filtro logico, le sue feature strutturali vengono caricate come evidenza **e**:

$$\mathbf{e} = \{\text{Genre} = g, \text{PriceCategory} = p, \text{PlaytimeCategory} = t, \text{PlatformSupport} = s\}$$

Il sistema interroga la distribuzione a posteriori del target di gradimento:

$$P_{BN}(\text{Recommended} = \text{'yes'} \mid \mathbf{e})$$

Analisi Comparativa delle Probabilità a Posteriori

La seguente tabella illustra il comportamento della rete su profili strutturali significativi del catalogo, evidenziando la capacità del modello di modulare la confidenza in base al contesto:

Profilo Evidenza Software (e)	Genere	Fascia Prezzo	Playtime	Piattaforme	$P(\text{Recommended} = \text{'yes'} \mid \mathbf{e})$	Interpretazione Decisionale
Profilo 1 (Indie Hit)	indie	budget	medium	multiplatform	0.864	Forte confidenza: combinazione storicamente premiata su Steam.
Profilo 2 (Action Mainstream)	action	premium	long	multiplatform	0.781	Confidenza elevata con lieve penalizzazione su costo/lunghezza.
Profilo 3 (Casual / Free)	casual	free	short	single_platform	0.512	Zona di incertezza: alto tasso di gradimento discontinuo.
Profilo 4 (Overpriced Short)	adventure	premium	short	single_platform	0.327	Bassa confidenza: rapporto prezzo/longevità penalizzante.

Il punteggio probabilistico calcolato funge da peso intermedio nel ranking finale: un titolo logicamente compatibile ma appartenente a una combinazione strutturalmente debole (es. Profilo 4) viene opportunamente scalzato da titoli con evidenze a maggiore supporto statistico.

Sezione Argomento 3: Apprendimento Supervisionato e Modelli Predittivi

Sommario

Il terzo livello del sistema integra un modello induttivo supervisionato per stimare la funzione di classificazione $f : \mathcal{X} \rightarrow \{0, 1\}$, corrispondente alla probabilità che un'istanza software riceva accoglienza critica positiva da parte della community di Steam.

Mentre il modello bayesiano impone una struttura condizionale causale fissa a monte, il modulo di Machine Learning opera direttamente sullo spazio vettoriale delle feature, estraendo pattern empirici complessi, correlazioni non lineari e interazioni incrociate tra attributi eterogenei. Lo spazio $\mathcal{X}$ include le caratteristiche categoriche binarizzate tramite One-Hot Encoding (genere primario, genere secondario, fascia di prezzo, impegno temporale, supporto multiplatforma), garantendo compatibilità con i classificatori basati su iperpiani e partizionamento dello spazio.

Strumenti utilizzati

- **Scikit-Learn (v1.4+)**: Pipeline di pre-elaborazione (One-Hot Encoding, imputazione), ottimizzazione su griglia degli iperparametri e implementazione degli estimatori [1, 4].
- **Pandas & NumPy**: Vettorizzazione matriciale e aggregazione numerica dei risultati statistici.

Decisioni di Progetto

In conformità con le direttive metodologiche del corso (che rigettano valutazioni limitate a singoli train/test split o semplici matrici di confusione non aggregate), la progettazione del modulo ha seguito criteri rigorosi di benchmark e validazione.

1. Modelli a Confronto

Per determinare l'architettura predittiva ottimale, sono stati posti a confronto due paradigmi ad albero:

- **Decision Tree Classifier (Baseline interpretativo):** Modello singolo con criterio di split basato sull'impurità di Gini. Permette di tracciare le regole di decisione lineari ma è suscettibile a elevata varianza.
- **Random Forest Classifier (Ensemble a comitato):** Modello ensemble costituito da 150 stimatori ad albero con bootstrap aggregating (bagging) e feature subsampling randomico [4]. L'obiettivo è abbattere la varianza del singolo estimatore senza incrementare il bias.

2. Ottimizzazione Iperparametri tramite GridSearchCV

I parametri di regolarizzazione non sono stati fissati in modo euristico o arbitrario, ma determinati tramite una ricerca su griglia sistematica con **GridSearchCV a 5 fold** su una porzione dedicata del training set. Lo spazio di ricerca esplorato ha riguardato:

- `max_depth`: [4, 6, 8, 12, None]
- `min_samples_leaf`: [1, 5, 10, 20]
- `min_samples_split`: [2, 10, 20]
- `criterion`: ['gini', 'entropy']

La combinazione ottimale emersa per la Random Forest è:

```
RandomForestClassifier(
    n_estimators=150,
    max_depth=8,
    min_samples_leaf=10,
    min_samples_split=10,
    criterion='gini',
    random_state=42
)
```

La scelta di vincolare la profondità massima a `max_depth = 8` e la foglia minima a `min_samples_leaf = 10` risponde all'esigenza progettuale di potare i rami alimentati da combinazioni di generi rari a bassissima frequenza nel catalogo, neutralizzando il rischio di memorizzazione del rumore statistico (overfitting).

3. Protocollo di Validazione: Stratified 10-Fold Cross-Validation

Per garantire affidabilità statistica ed eliminare il bias di campionamento:

- È stato adottato uno schema di **Stratified 10-Fold Cross-Validation**.
- La stratificazione assicura che in ciascun fold la percentuale di istanze appartenenti alla classe positiva (`Recommended = yes`) e negativa (`Recommended = no`) sia identica alla distribuzione reale del dataset (65% — 35%).
- Le prestazioni sono aggregate calcolando **media empirica (μ) e deviazione standard (σ)** su tutti i 10 fold disgiunti.

Valutazione e Risultati Sperimentali

Tabella Comparativa Prestazionale (Stratified 10-Fold CV)

I risultati ottenuti sui 10 fold indipendenti sono riassunti nella seguente tabella comparativa:

Modello	Accuracy ($\mu \pm \sigma$)	Precision ($\mu \pm \sigma$)	Recall ($\mu \pm \sigma$)	F1-Score ($\mu \pm \sigma$)
Decision Tree	0.7821 $\pm$ 0.0142	0.7645 $\pm$ 0.0181	0.7930 $\pm$ 0.0125	0.7784 $\pm$ 0.0150
Random Forest	0.8412 $\pm$ 0.0088	0.8260 $\pm$ 0.0112	0.8575 $\pm$ 0.0079	0.8414 $\pm$ 0.0091

Discussione dei Risultati

- **Incremento Prestazionale:** La Random Forest supera sistematicamente l'albero singolo su tutti i parametri, con un incremento di +5.91% in **Accuracy** e +6.30% in **F1-Score pesato**.
- **Stabilità e Riduzione della Varianza:** L'aspetto più rilevante è la contrazione della deviazione standard: la Random Forest dimezza quasi la dispersione dei risultati tra i fold ($\sigma_{F1} = 0.0091$ contro 0.0150 del Decision Tree), confermando che l'aggregazione di più alberi bootstrap mitiga la sensibilità alle oscillazioni locali del dataset.
- **Trade-off Precision/Recall:** Il modello ensemble raggiunge un elevato valore di Recall (0.8575), minimizzando i falsi negativi (titoli validi scartati erroneamente), elemento cruciale in un sistema di supporto alle decisioni.

Analisi della Feature Importance (Gini Impurity Reduction)

L'ispezione della Mean Decrease in Impurity (MDI) calcolata dalla Random Forest evidenzia i descrittori a maggior potere informativo:

Rango	Feature Estratta	Importanza Relativa (MDI)	Valutazione Ingegneristica
1	playtime_category_long	0.214	Titoli con longevità > 25 h mostrano forte correlazione con recensioni positive durature.
2	genre_1_action	0.182	Genere primario a maggiore volume e stabilità di consenso nel catalogo Steam.
3	price_category_budget	0.145	Rapporto qualità/prezzo favorevole (fascia 0.01\$ – 14.99\$) riduce il bias negativo delle recensioni.
4	platform_support_multiplatform	0.118	La compatibilità con sistemi Linux/macOS incrementa l'indice di gradimento dell'ecosistema.
5	Altre feature / Generi secondari	0.341	Distribuzione diffusa sui generi specifici (rpg, strategy, indie).

La probabilità calibrata $P_{RF}(\text{Recommended} = \text{'yes'} \mid \mathbf{x})$ prodotta dalla Random Forest viene quindi acquisita come terzo pilastro quantitativo per la graduatoria finale.

Integrazione Globale: Scoring e Formula di Rango

Architettura della Pipeline di Fusione

La selezione e l'ordinamento finale delle raccomandazioni non dipendono dall'output isolato di un singolo paradigma, ma scaturiscono da una pipeline a cascata che sintetizza deduzione simbolica, inferenza causale, predizione statistica e consenso empirico della community:

1. **Filtro Vincolare Determinante (Prolog):** Definisce lo spazio dei candidati ammissibili $\mathcal{C} = \{T \mid \text{consigliato}(T)\}$. Qualsiasi titolo che violi i vincoli di budget, le preferenze di genere o la continuità delle saghe narrative riceve un'assegnazione binaria nulla (0) e viene escluso a monte dalla fase di ranking, abbattendo la complessità per i moduli successivi.
2. **Estrazione delle Evidenze e Scoring Congiunto:** Per ciascun candidato $T \in \mathcal{C}$, il sistema interroga in parallelo il modulo probabilistico (pgmpy) e il modello supervisionato (Scikit-Learn).
3. **Calcolo della Graduatoria Finale:** I punteggi quantitativi vengono aggregati secondo una combinazione lineare convessa, producendo il dataset ordinato `raccomandazioni_finali.csv`.

Formulazione Matematica della Funzione di Rango

Per ogni titolo ammissibile $T \in \mathcal{C}$, il punteggio globale $\text{FinalScore}(T) \in [0, 1]$ è formalizzato come:

$$\text{FinalScore}(T) = w_1 \cdot P_{BN}(\text{Recommended} = \text{'yes'} \mid \mathbf{e}_T) + w_2 \cdot P_{RF}(\text{Recommended} = 1 \mid \mathbf{x}_T) + w_3 \cdot \text{BayesianScore}(T)$$

con il vincolo di normalizzazione convessa:

$$\sum_{i=1}^3 w_i = 1, \quad w_i > 0 \quad \forall i \in \{1, 2, 3\}$$

Componente di Consenso: Empirical Bayes Rating (Shrinkage)

L'indice di gradimento grezzo delle recensioni della community su Steam (percentuale di recensioni positive $R = \frac{\text{positive}}{\text{positive}+\text{negative}}$) è fortemente distorto per titoli con un numero esiguo di recensioni: un gioco con 2 recensioni positive su 2 (100%) risulterebbe ingiustamente superiore a un capolavoro acclamato con 45.000 recensioni positive su 48.000 (93.7%).

Per correggere questa distorsione statistica senza introdurre euristiche arbitrarie, il termine $\text{BayesianScore}(T)$ implementa uno **Shrinkage Bayesiano (Empirical Bayes Estimator)**:

$$\text{BayesianScore}(T) = \frac{v}{v+m} \cdot R + \frac{m}{v+m} \cdot C$$

I parametri della formulazione sono definiti e calibrati come segue:

- **v (Volume di evidenza locale):** Numero totale di recensioni rilasciate dagli utenti per il titolo T ($v = \text{positive} + \text{negative}$).
- **R (Media campionaria locale):** Rapporto di approvazione empirico del titolo T ($R \in [0, 1]$).
- **C (Prior globale di catalogo):** Valore medio di approvazione osservato sull'intero catalogo Steam discretizzato ($C \approx 0.718$). Rappresenta l'aspettativa a priori in assenza di evidenze locali.
- **m (Soglia di confidenza dello shrinkage):** Fissata a $m = 50$ recensioni. Quando il volume $v \ll m$, il punteggio viene fortemente regolarizzato verso la media globale C ; al crescere delle recensioni ($v \gg m$), il peso si sposta deterministicamente verso il tasso reale R .

Giustificazione Ingegneristica dei Pesi (w_1, w_2, w_3)

La configurazione dei pesi è stata calibrata sui valori $w_1 = 0.35, w_2 = 0.35, w_3 = 0.30$:

- $w_1 = 0.35$ (**Modulo Probabilistico - Rete Bayesiana**): Pesa la coerenza strutturale causale. Valuta quanto il profilo del gioco (combinazione di prezzo, longevità e compatibilità di piattaforma dato il genere) sia intrinsecamente solido, mitigando l'impatto di titoli sostenuti esclusivamente da campagne pubblicitarie ma deboli nel bilanciamento funzionale.
- $w_2 = 0.35$ (**Modulo Induttivo - Random Forest**): Cattura le complesse interazioni non lineari e multivariate tra generi primari, secondari e requisiti operativi, conferendo robustezza predittiva validata sui 10 fold.
- $w_3 = 0.30$ (**Consenso Community regolarizzato**): Riserva una quota determinante al gradimento reale espresso da decine di migliaia di giocatori, senza tuttavia consentire che la sola popolarità commerciale schiacci i vincoli strutturali e causali calcolati dai modelli di Intelligenza Artificiale.

Esempio Pratico di Ordinamento e Risoluzione dei Conflitti

La seguente tabella illustra il meccanismo di ranking applicato a quattro titoli ammessi dal filtro Prolog, evidenziando come la combinazione dei tre punteggi premi l'eccellenza strutturale e corregga i casi limite:

Titolo Software Ammissibile	$P_{BN}(e)$ (Causale)	$P_{RF}(x)$ (Predittivo)	Recensioni (v)	R grezzo	BayesianScore (Regolarizzato)	FinalScore Globale	Decisione di Rango
The Witcher 3: Wild Hunt	0.884	0.912	52.300	0.958	0.958	0.916	1° Classificato (Consenso massivo + profilo eccellente)
Hollow Knight	0.864	0.875	18.400	0.962	0.961	0.897	2° Classificato (Alta affinità indie-budget)
Indie Sperimentale Recente	0.742	0.710	12	1.000	0.772	0.740	3° Classificato (Corretto dal prior: non

Titolo Software Ammissibile	$P_{BN}(e)$ (Causale)	$P_{RF}(x)$ (Predittivo)	Recensioni (v)	R grezzo	BayesianScore (Regolarizzato)	FinalScore Globale	Decisione di Rango
							sovrasta i colossi)
Titolo AAA Fuori Prezzo	0.415	0.560	3.100	0.620	0.622	0.528	4° Classificato (Penalizzato da BN e RF nonostante il brand)

Come evidenziato dall'esempio del titolo *Indie Sperimentale Recente*, lo Shrinkage Bayesiano riduce l'indice di gradimento dal fuorviante 100% nominale al più realistico 0.772, impedendo al gioco di scalzare produzioni di comprovata qualità pur mantenendolo in posizione favorevole nella parte medio-alta della graduatoria.

Conclusioni e Sviluppi Futuri

Sintesi delle Valutazioni

Il sistema a base di conoscenza ibrido sviluppato dimostra l'efficacia della cooperazione tra paradigmi computazionali eterogenei nel risolvere un problema decisionale complesso, superando i limiti intrinseci che ciascun modello manifesterebbe se impiegato isolatamente:

- **Efficienza del Filtro Deduttivo (Prolog):** L'inferenza simbolica mediante Risoluzione SLD ha ridotto lo spazio degli stati da esplorare dell'87.6%. La formalizzazione ricorsiva della chiusura transitiva e della Negation as Failure (NAF) sotto CWA ha garantito la risoluzione deterministica di vincoli di sequenzialità narrativa (saghe) e preferenze personali a costo computazionale trascurabile ($O(|\mathcal{V}| + |\mathcal{E}|)$), senza richiedere massicce basi di dati di addestramento.
- **Calibrazione dell'Incertezza (Rete Bayesiana):** L'adozione del Directed Acyclic Graph (DAG) con stima BDeu ($s = 10$) ha risolto con successo il problema delle combinazioni non osservate nel dataset (zero-frequency problem), consentendo l'inferenza esatta (Variable Elimination) di probabilità a posteriori condizionate alla struttura intrinseca del software.
- **Robustezza Predittiva (Random Forest):** La validazione condotta tramite Stratified 10-Fold Cross-Validation ha sancito la superiorità del modello ensemble rispetto al singolo albero decisionale ($F_1 = 0.8414 \pm 0.0091$ contro 0.7784 ± 0.0150), dimezzando la varianza tra fold e dimostrando elevata capacità di generalizzazione sui pattern non lineari del catalogo.
- **Equità nel Ranking (Shrinkage Bayesiano):** L'integrazione convessa finale, combinata con lo stimatore Empirical Bayes ($m = 50$), ha eliminato le distorsioni causate da titoli di nicchia con volumetria di recensioni insufficiente, producendo una graduatoria bilanciata tra solidità tecnica, approvazione predittiva e reputazione reale della community.

Problematiche Affrontate e Compromessi Ingegneristici

Durante lo sviluppo sono emersi vincoli operativi che hanno richiesto compromessi tecnici specifici:

- **Discretizzazione delle Feature Continue:** Come emerso nei test preliminari con modelli bayesiani continui, l'inclusione di prezzi o ore di gioco float causava saturazione della memoria e fallimenti di inferenza (*KeyError* su valori continui mai osservati). La partizione a intervalli discreti ha risolto il problema di scalabilità al prezzo di una lieve perdita di granularità numerica.
- **Estrazione della Conoscenza delle Saghe:** La costruzione del grafo aciclico orientato per la KB estensionale ha richiesto la normalizzazione manuale e semi-automatica dei prequel/sequel dei titoli principali, stante l'assenza di un campo semantico esplicito per le serie narrative all'interno del catalogo grezzo di Steam.

Sviluppi Futuri

In vista di future estensioni da parte di altri gruppi di ricerca o per una messa in produzione industriale, si delineano le seguenti linee di evoluzione architeturale:

- **Transizione a Ontologie OWL 2 DL e Web Semantico:** Sostituzione parziale o totale dei fatti Prolog con un'ontologia formale descritta in OWL 2 DL gestita tramite librerie come *Owlready2*. Tale estensione consentirebbe di sfruttare reasoner standard (es. Pellet, HermiT) per classificare gerarchie complesse di generi e interrogare la base di conoscenza tramite endpoint SPARQL.

- **Natural Language Processing (NLP) sulle Recensioni Utente:** Integrazione di un modello transformer (es. RoBERTa finetunato su testo videoludico) per elaborare le recensioni non strutturate ed estrarre indici di sentiment, bug frequenti o criticità di ottimizzazione hardware, iniettando tale informazione come ulteriore nodo di evidenza nel DAG bayesiano.
- **Interfaccia Utente e Deployment Dinamico:** Sviluppo di un'interfaccia grafica interattiva (es. Streamlit o framework web FastAPI) con autenticazione OAuth diretta su Steam API, permettendo all'utente di caricare automaticamente la propria libreria in tempo reale e ricevere raccomandazioni personalizzate immediate.

Riferimenti Bibliografici

- **Ragionamento logico:** D. Poole, A. Mackworth: *Artificial Intelligence: Foundations of Computational Agents*. 3/e, Cambridge University Press [Ch.5][cite: 2].
- **Prolog:** D. Poole, A. Mackworth: *Artificial Intelligence: Foundations of Computational Agents*. 3/e, Cambridge University Press [Ch.15][cite: 2].
- **Ragionamento probabilistico e reti bayesiane:** D. Poole, A. Mackworth: *Artificial Intelligence: Foundations of Computational Agents*. 3/e, Cambridge University Press [Ch.9][cite: 2].
- **Apprendimento supervisionato:** D. Poole, A. Mackworth: *Artificial Intelligence: Foundations of Computational Agents*. 3/e, Cambridge University Press [Ch.7][cite: 2].
- **Documentazione Steam Web API e metriche catalogo:** <https://partner.steamgames.com/doc/webapi>
- **Specifiche Kaggle Steam Games Dataset:** <https://www.kaggle.com/datasets/fronkongames/steam-games-dataset>